Apache Cassandra 2.0 vspace2exPrzewodnik instalacji i konfiguracji w systemie Debian Wheezy

Jan Baranowski, Michał Kaik Politechnika Poznańska

18 czerwca 2014

1 Wstęp

Niniejszy dokument ma za zadanie przedstawić proces instalacji i konfiguracji serwera baz danych NoSQL *Apache Cassandra* w środowisku rozproszonym. Na potrzeby demonstracji zakłada się że środowisko to będzie składać się z kilku węzłów połączonych siecią lokalną.

Apache Cassandra jest serwerem baz danych NoSQL, początkowo rozwijanym przez Facebooka na potrzeby umożliwienia efektywnego wyszukiwania wiadomości w skrzynce odbiorczej. Obecnie (od marca 2009 roku) Cassandra jest rozwijana przez Apache Foundation (jako jeden z projektów top-level) i stanowi podstawę dla zestawu narzędzi DataStax.

Cassandra powstała jako narzędzie mające w założeniu cechować się:

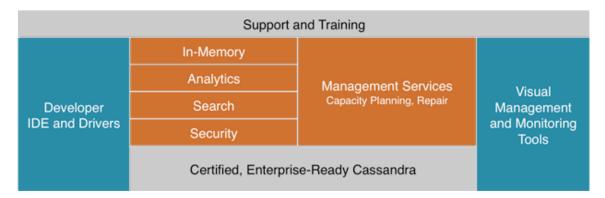
- wysoką dostępnością (Cassandra jest określana jako zawsze zapisywalna baza danych)
- niskim opóźnieniem wykonywanych operacji (ang. latency)
- odpornością na awarie (możliwością replikacji danych, brakiem komponentów, których awaria może zdestabilizować system (ang. single points of failure))
- możliwością regulacji kompromisu pomiędzy szybkością działania a odpornością na awarie i spójnością replik
- relatywnie prostym modelem danych

Zarówno opisanie kolumnowego modelu danych wykorzystywanego w Cassandrze, jak i mechanizmów, dzięki którym spełnia ona założenia projektowe nie jest celem tego dokumentu. Autorzy mogą jedynie podać propozycje publikacji, które opisują wspomniane zagadnienia. Zarówno dla modelu danych, jak i budowy wewnętrznej Cassandry będzie to przede wszystkim dokumentacja udostępniana przez firmę DataStax [4]. Kolumnowy model danych, przedstawiony z perspektywy osób pracujących z bazami relacyjnymi został doskonale (choć może zbyt obszernie) opisany w Cassandra — The Definitive Guide [3]. Z kolei architektura Cassandry w dużym skrócie (choć zapewne w sposób wystarczający by służyć jako wstęp do tego dokumentu) została przedstawiona w prezentacji [2].

Procedurę przygotowania klastra przedstawiono na przykładzie systemu operacyjnego Debian $\mathrm{GNU}/\mathrm{Linux}$ 6, ponieważ uchodzi on za jedno z lepszych rozwiązań dla serwerów.

2 Wybór dystrybucji

Na samym początku nowi użytkownicy Cassandry stają przed wyborem dystrybucji tego oprogramowania. Możliwości są dwie: instalacja standardowej wersji dostarczonej przez Apache Foundation oraz instalacja platformy DataStax — zestawu narzędzi obudowujących Cassandrę i dostarczających m.in. funkcje pozwalające na uproszczenie zarządzania klastrem, wizualne monitorowanie, analizę obciążeń węzłów, itp. (por. rysunek 1).



Rysunek 1: architektura DataStax w odniesieniu do Cassandry, źródło: [15]

Wybór jest ważny o tyle, że pomimo wspólnego fundamentu, jakim jest *Cassandra*, procesy instalacji obu dystrybucji nie mają ze sobą nic wspólnego, tj. (według wiedzy autorów) nie da się doinstalować do dystrybucji *Apache* platformy *DataStax*.

W tym miejscu należy wspomnieć o twórcach platformy — firmie o zaskakującej nazwie DataStax, zajmującej się dostosowaniem Cassandry do potrzeb przedsiębiorstw poprzez m.in. rozwój i testowanie bazy danych, dostarczanie narzędzi ułatwiających administrację systemem, organizację szkoleń, certyfikację personelu technicznego, itd. Bodaj najbardziej znaczącym wkładem DataStax w rozwój projektu jest opracowanie szeregu driverów/konektorów dla różnych języków programowania, dzięki którym programiści mogą korzystać z Cassandry w sposób analogiczny do rozwiązań relacyjnych (np. tak jak w przypadku MySQL Connectors, por. [11]) i rozbudowa dokumentacji technicznej platformy, włączając w to dokumentację plików konfiguracyjnych, architektury Cassandry i języka CQL (odpowiednika SQL dla kolumnowych baz danych).

Na potrzeby niniejszego dokumentu założono, że właściwym wyborem będzie dystrybucja Apache Cassandra, ze względu na to, że dokument ma pełnić rolę wprowadzenia do technologii, nie zaś pozwalać na błyskawiczne wdrożenie systemu (ang. rapid deployment). Poza tym, przewodniki instalacji i konfiguracji DataStaxa dostępne są np. na stronie [12].

3 Instalacja

Cassandra zostanie zainstalowana przy użyciu narzędzia APT z repozytorium Apache Software Foundation. Wymagane będzie dodanie odpowiedniego repozytorium do listy źródeł APTa. Dodatkowo ze względu na to, że Cassandra napisana jest w Javie, pokazany zostanie proces instalacji Oracle JRE w systemie Debian (ta maszyna wirtualna jest zalecana przez twórców Cassandry).

3.1 Wybór maszyny wirtualnej Java

Apache Software Foundation dostarcza pakiety zawierające Cassandrę w formacie *.deb, a także repozytorium dla APTa. Jedną z zależności pakietu cassandra jest pakiet openjdk-7-jre. Jest to w pewnym sensie sprzeczne z zaleceniami twórców bazy danych, ponieważ ci rekomendują maszynę wirtualną Oracle jako środowisko uruchomieniowe (nawet w testowanej wersji bazy 2.0 odpowiedni

komunikat wyświetlany jest w logu). Nie zmienia to faktu, że testy (funkcjonalne, lecz nie wydajnościowe) przeprowadzone na potrzeby tego artykułu udowodniły, że Cassandra działa bez zarzutu także w środowisku OpenJDK.

Należy zatem wybrać pomiędzy stosowaniem się do zaleceń a prostotą instalacji.

3.2 Instalacja i konfiguracja Oracje Java

Pakiet z *OpenJDK* jest instalowany jako pakiet zależny podczas instalacji Cassandry. Jeżeli jednak administrator zdecyduje się użyć *Oracle JVM*, poniżej przedstawiona jest skrótowa procedura instalacji tego oprogramowania w systemie *Debian*. Stanowi ona kompilację najprostszych rozwiązań i tym różni się od większości przewodników dostępnych w internecie, że poza konsolą systemu nie wymaga żadnych dodatkowych narzędzi (np. mechanizmu transferu plików z maszyny-terminala do maszyny-serwera).

Pierwszym krokiem jest pobranie pakietu oprogramowania (JRE, nie JDK) ze strony *Oracle*. Standardowo by pobrać plik należy zaakceptować umowę licencyjną, jednak przy odpowiedniej konfiguracji możliwe jest ominiecie tego kroku [9]:

Listing 1: pobieranie Oracle JRE

```
$ wget --no-cookies \
> --no-check-certificate \
> --header "Cookie: oraclelicense=accept-securebackup-cookie" \
> "http://download.oracle.com/otn-pub/java/jdk/7u60-b19/jre-7u60-linux-i586.tar.gz" \
> -0 /tmp/jre-7u60-linux-i586.tar.gz
```

Popularnym sposobem instalacji pobranego oprogramowania jest wypakowanie archiwum (zazwyczaj do katalogu /opt) i ręczna konfiguracja ścieżki systemowej (por. [9]). Debian dostarcza jednak narzędzie pozwalające przekonwertować archiwum do pakietu DEB [10].

Należy je zainstalować, a potem użyć:

Listing 2: budowa pakietu DEB z Oracle JRE

```
$ apt-get install java-package
$ fakeroot make-jpkg /tmp/jre-7u60-linux-i586.tar.gz
```

Powstały w ten sposób pakiet DEB należy zainstalować. Po instalacji należy ustawić Oracle JVM jako domyślną maszynę wirtualną w systemie.

Listing 3: instalacja i konfiguracja Oracle JRE

Według wiedzy autorów Cassandra nie wymaga ustawiania zmiennej JAVA_HOME dla żadnego z użytkowników (ani roota, ani użytkownika *cassandra*, właściciela demona). Jeżeli jednak zajdzie taka potrzeba, zainstalowane maszyny wirtualne można znaleźć w katalogu /usr/lib/jym.

```
Listing 4: ustawianie JAVA HOME
```

```
$ echo "export JAVA_HOME=/usr/lib/jvm/j2re1.7-oracle/" >> /home/<user>/.bashrc
```

3.3 Konfiguracja repozytorium

By móc zainstalować Cassandrę, należy dodać odpowiednie repozytorium Apache Software Foundation do źródeł programu APT. Zgodnie z konwencją każda większa wersja Cassandry znajduje się w osobnym repozytorium. Na potrzeby tego dokumentu w systemie testowym zostanie zainstalowana Cassandra 2.0.8.

Do pliku /etc/apt/sources.list należy dopisać:

Listing 5: nowe źródła pakietów dla APTa

```
deb http://www.apache.org/dist/cassandra/debian 20x main
deb-src http://www.apache.org/dist/cassandra/debian 20x main
```

Próba pobrania spisu zawartości repozytorium zakończy się niepowodzeniem, ponieważ APT nie zna kluczy publicznych dla repozytorium $Apache\ Software\ Foundation$. Te należy dodać w następujący sposób:

Listing 6: pobieranie kluczy publicznych repozytorium ASF

```
$ gpg --keyserver pgp.mit.edu --recv-keys F758CE318D77295D
$ gpg --export --armor F758CE318D77295D | sudo apt-key add -
$ gpg --keyserver pgp.mit.edu --recv-keys 2B5C1B00
$ gpg --export --armor 2B5C1B00 | sudo apt-key add -
```

Po zakończeniu wszystkich operacji należy pobrać spis zawartości repozytoriów:

Listing 7: odświeżanie list pakietów

```
$ apt-get update
```

3.4 Instalacja Cassandry

Ostatnim krokiem procesu instalacji jest zainstalowanie Cassandry z użyciem APTa:

Listing 8: instalacja Cassandry

```
$ apt-get install cassandra
```

W efekcie Cassandra powinna zostać zainstalowana i uruchomiona.

4 Konfiguracja węzła

Ta część dokumentu opisuje czynności związane z konfiguracją węzła Cassandry tak, by był on zdolny dołączyć do klastra. Cassandra jest systemem P2P, więc o utworzeniu klastra węzły decydują wspólnie w oparciu o taką samą nazwę klastra zdefiniowaną w pliku konfiguracyjnym i włączony kanał komunikacji poprzez plotkowanie. Kanał ten jest domyślnie wyłączony, zatem każdy węzeł Cassandry w sieci będzie z początku tworzył osobny klaster.

4.1 Stan systemu po instalacji

Zaraz po instalacji w systemie pojawia się nowa usługa: cassandra. Jest ona domyślnie uruchomiona. Jej konfiguracja zapobiega możliwości dołączenia węzła do jakiegokolwiek klastra ze względu na zablokowanie mechanizmu plotkowania (dokładnie: agent implementujący algorytm plotkujący nasłuchuje wyłącznie na adresie IP 127.0.0.1).

Pliki konfiguracyjne można znaleźć w katalogu /etc/cassandra. Są wśród nich:

- /etc/cassandra/cassandra-env.sh skrypt definiujący zmienne środowiskowe w formie argumentów dla maszyny wirtualnej Java (np. wielkość stosu, ale także m.in. włączenie/wyłączenie mechanizmu JMX).
- /etc/cassandra/cassandra-rackdc.properties informacja o tym, w którym fizycznie racku i centrum danych znajduje się obecny węzeł.
- /etc/cassandra/cassandra-topology.properties przybliżone informacje o tym, w których rackach i centrach danych znajdują się inne węzły klastra. Plik ten jest wykorzystywany przez jedną z kilku wersji algorytmu rozmieszczania replik (snitcha).
- /etc/cassandra/cassandra-topology.yaml plik analogiczny do poprzedniego, wykorzystywany jednak przez inną wersję algorytmu.
- /etc/cassandra/cassandra.yaml główny plik konfiguracyjny Cassandry.

Pliki danych (w tym: commit logi) znaleźć można w katalogu /var/lib/cassandra. Czyszcząc zawartość trzech znajdujących się w nim podkatalogów można zresetować stan klastra. W celu wykonania tej czynności autorzy nie zalecają jednak ich całkowitego usuwania (podczas testowania mogą one zostać utworzone na nowo z prawem zapisu tylko dla roota, co uniemożliwi normalny start usługi).

Plik logu znaleźć można w /var/log/cassandra/system.log.

4.2 Jak debugować konfigurację?

Przed rozpoczęciem wprowadzania zmian do plików konfiguracyjnych zaleca się wyłączenie automatycznego uruchamiania usługi. Błędnie skonfigurowany węzeł może dołączyć do nieodpowiedniego klastra, a jego usunięcie w takim przypadku nie jest zadaniem trywialnym. Efekt można osiągnąć wykonując polecenie:

Listing 9: wyłączenie uruchamiania Cassandry na jej domyślnych runlevelach

\$ insserv -r cassandra

Najprostszym sposobem sprawdzenia poprawności konfiguracji jest uruchomienie węzła w trybie jawnym (w przeciwieństwie do deamona). Służy do tego podane poniżej polecenie, które wypisze log działania węzła na standardowe wyjście.

Listing 10: testowe uruchamianie Cassandry

\$ cassandra -f # -f for foreground

Dodatkowo można zarchiwizować taki log poleceniem tee plik.log, które skopiuje standardowe wejście na standardowe wyjście i do podanego pliku:

Listing 11: testowe uruchamianie Cassandry z archiwizacją logu

\$ cassandra -f | tee /tmp/cassandra_testrun.log

UWAGA! Jeżeli *Cassandra* zostanie uruchomiona w trybie jawnym podczas gdy równolegle usługa działa w tle, zamiast informacji o błędzie w logu tej pierwszej pojawi się informacja o wyjątku NullPointerException.

UWAGA! Jeżeli pierwsze uruchomienie *Cassandry* odbędzie się w trybie jawnym z poziomu użytkownika innego niż **cassandra**, usługa nie będzie miała prawa zapisu do nowo utworzonych katalogów danych, nie będzie więc w stanie się uruchomić.

UWAGA! Jeżeli zmienna JAVA_HOME dla użytkownika uruchamiającego polecenie cassandra -f jest ustawiona, ale prowadzi do niepoprawnie zainstalowanej maszyny wirtualnej, *Cassandra* nie uruchomi się, ale ani skrypt startowy ani log nie poinformują o błędzie.

4.3 Pliki konfiguracyjne

Role podstawowych plików konfiguracyjnych zostały przedstawione w punkcie 4.1. W tabeli 1 zostaną opisane parametry konfiguracyjne (z /etc/cassandra/cassandra.yaml), których wartości powinny zostać świadomie dobrane przed uruchomieniem pojedynczego węzła.

Konfigurację węzła ułatwia sam plik konfiguracyjny ${\it Cassandry},$ zawierający obszerne komentarze.

4.4 Weryfikacja stanu węzła

Szeroko pojęty stan węzła po konfiguracji można sprawdzić na kilka sposobów. Przede wszystkim po uruchomieniu usługi należy sprawdzić czy ta faktycznie działa i gdy tak nie jest, przejrzeć log.

W następnej kolejności można sprawdzić czy *Cassandra* nasłuchuje na portach zdefiniowanych w pliku konfiguracyjnym:

Listing 12: sprawdzanie na których portach nasłuchuje Cassandra

```
$ netstat -ln4p #listening, numeric, IPv4 only, with owner process information
```

Kolejnym sposobem jest próba połączenia się z węzłem poprzez Thrift API.

Listing 13: dostęp do Cassandry przez Thrift API.

```
$ cqlsh localhost 9160 #use "quit;" to exit CQL shell
```

Wreszcie można wyświetlić stan klastra, do którego należy węzeł:

Listing 14: sprawdzanie stanu klastra

5 Konfiguracja klastra

5.1 Łaczenie wezłów w klaster

Zakładając, że odpowiednie węzły spełniają następujące warunki:

nazwa klastra w plikach konfiguracyjnych wszystkich węzłów jest taka sama

- agent algorytmu plotkującego nasłuchuje na adresie IP interfejsu osiągalnego z sieci lokalnej (parametr listen_address)
- początkowe punkty kontaktowe są zdefiniowane tak by każdy węzeł mógł ostatecznie dowiedzieć się o wszystkich pozostałych

by połączyć je w klaster wystarczy jedynie uruchomić na nich usługę cassandra.

5.2 Weryfikacja konfiguracji klastra

Połączenia między węzłami klastra mają charakter dwukierunkowy. Oznacza to, że jeżeli węzeł nie jest widoczny w sieci, to (o ile działa) sam także nie widzi pozostałych węzłów.

Stąd najprostszym sposobem na sprawdzenie czy wszystkie węzły zostały odpowiednio połączone jest sprawdzenie jaki stan klastra widzi dowolny z jego węzłów. Informację tę może podać narzędzie nodetool.

Listing 15: sprawdzanie stanu klastra po dołączeniu węzłów

```
$ nodetool -host localhost -p 7199 status
Note: Ownership information does not include topology; for complete information,
specify a keyspace
Datacenter: DC1
=========
Status=Up/Down
|/ State=Normal/Leaving/Joining/Moving
-- Address Load Tokens Owns Host ID Rack
UN 10.0.0.101 63.38 KB 256 35.3% c6b6661a-c501-45ad-acc1-3e17fea6d241 NODE1AND2
UN 10.0.0.100 63.48 KB 256 31.0% c45900c6-6866-4b5a-b32b-cc0158bca524 NODE0
UN 10.0.0.102 63.5 KB 256 33.7% 4d598617-7f3c-480c-9310-f0eae90ef96b NODE1AND2
```

Jeżeli jeden z węzłów nie dołączył do klastra lub znajduje się w stanie DOWN, należy sprawdzić czy uruchomił się prawidłowo, czy log nie zawiera informacji o błędzie sieci lub agenta algorytmu plotkującego (w pewnych sytuacjach taki błąd nie powstrzymuje usługi przed uruchomieniem), wreszcie czy adres IP dla agenta i początkowe punkty kontaktowe zostały poprawnie zdefiniowane w pliku konfiguracyjnym.

UWAGA! Z zawartości pliku konfiguracyjnego /etc/cassandra/cassandra.yaml można wnioskować, że zawsze jednym z punktów kontaktowych powinien być localhost. Jako adres IP punktu nie powinien być jednak podawany adres 127.0.0.1, lecz adres interfejsu na którym nasłuchuje agent (parametr listen_address).

5.3 Działania dodatkowe

W obecnym stanie klaster powinien już działać prawidłowo. Każdy węzeł powinien przyjmować od użytkowników zapytania i odpowiadać na nie w sposób adekwatny do stanu klastra.

Jednak by zapewnić stabilne działanie klastra przez dłuższy okres wymagane są dodatkowe czynności administracyjne.

5.3.1 Synchronizacja zegarów

Dokumentacja Cassandry udostępniona przez Apache Software Foundation wspomina o tym, że do oceny czy propagowane do węzłów zmiany schematu (np. dodanie nowej rodziny kolumn) są przedawnione (zatem powinny być zignorowane) wykorzystywany jest lokalny zegar czasu rzeczywistego (RTC).

By zapewnić poprawność propagacji takich zmian należy okresowo synchronizować zegary węzłów np. poprzez protokół NTP.

W systemie *Debian* funkcję synchronizacji czasu systemowego z serwerem NTP dostarcza pakiet ntp. Pakiet ten jest rekomendowany do instalacji przez pakiet cassandra. Po instalacji ntp automatycznie zostaje uruchomiona usługa ntp bazująca na puli serwerów dostarczonych razem z pakietem. Należy sprawdzić czy usługa ta jest zainstalowana, uruchomiona i czy serwery *NTP* są dostępne:

Listing 16: weryfikacja poprawności działania klienta NTP

5.3.2 Czyszczenie

 ${\it Cassandra}$ używa trzech mechanizmów w celu zapewnienia ostatecznej spójności replik. Są to kolejno:

- 1) mechanizm read-repair pozwalający uaktualnić te repliki, które zostaną wyznaczone jako nie-aktualne (a dzieje się to w momencie gdy pojedynczy węzeł zbierze dostatecznie dużo danych z różnych replik, tj. przy odczycie z dostatecznie wysokim poziomem spójności).
- 2) mechanizm *HintedHandoff* uprawniający punkt kontaktowy w klastrze do przechowania uaktualnienia do momentu gdy jego cel (o ile nie jest nim sam punkt kontaktowy) będzie osiągalny (tj. sam zostanie naprawiony lub połączenie z nim zacznie działać)
- 3) mechanizm *AntiEntropy* czyli wymuszona przez administratora synchronizacja koordynatora z wszystkimi zależnymi replikami

Spośród nich tylko trzeci mechanizm wymaga interwencji administratora.

Cassandra pozwala na usuwanie danych z bazy w sposób pod kątem zachowania spójności podobny do przeprowadzania zapisów. Jest to o tyle kłopotliwe, że podczas synchronizacji dane, które zostały usunięte mogą być potraktowane jako brakujące uaktualnienia. W efekcie dane raz usunięte mogą pojawić się ponownie nawet na tym samym weźle.

By temu zapobiec *Cassandra* zamiast faktycznie usuwać dane, oznacza je jako usunięte za pomocą specjalnej wartości, tzw. *tombstone*. To z kolei powoduje problem przyrastania danych nawet podczas ich usuwania.

By zapobiec i temu, *tombstony* w *Cassandrze* są przechowywane przez określony czas (definiowany podczas tworzenia przestrzeni kluczy, poprzez parametr gc_grace_seconds, domyślnie 10 dni [6]).

Stąd zaleca się wymuszenie synchronizacji replik (czyli uruchomienie mechanizmu AntiEntropy) częściej niż wynosi najmniejsza wartość gc_grace_seconds dla przestrzeni kluczy przechowywanych w węźle.

UWAGA! Problem nie będzie występował jeżeli aplikacja korzystająca z *Cassandry* wcale nie zleca usunięć wierszy.

UWAGA! Z drugiej strony pełna synchronizacja węzła z replikami jest kosztowna. Konstrukcja struktury *Merkle Tree*, wykorzystywanej do obliczenia różnic pomiędzy replikami wymaga odczytu wszystkich danych przechowywanych w węźle (w tym — tych zrzuconych na dysk). Należy więc ustalić kompromis pomiędzy obciążeniem systemu *tombstonami* a obciążeniem go procedurą synchronizacji.

Mechanizm AntiEntropy uruchamia się wymuszając pełną naprawę węzła narzędziem nodetool:

Listing 17: naprawa węzła poprzez uruchomienie mechanizmu AntiEntropy

```
$ nodetool -host localhost repair
[2014-06-17 21:47:55,488] Nothing to repair for keyspace 'system'
[2014-06-17 21:47:55,546] Starting repair command 2, repairing 474
ranges for keyspace system_traces
[2014-06-17 22:01:37,033] Repair session 0a4463e0-f669-11e3-8ad4-251897e18719 for
range (-2577486857218927215,-2576033184180305603] finished
[2014-06-17 22:01:37,038] Repair session 0b595650-f669-11e3-8ad4-251897e18719 for
range (-1096394548677781591,-1069256055695448190] finished
[...]
[2014-06-17 22:01:38,931] Repair session efaa5290-f66a-11e3-8ad4-251897e18719 for
range (4183239765725363167,4233658233454255946] finished
[2014-06-17 22:01:38,932] Repair session f0bc5ed0-f66a-11e3-8ad4-251897e18719 for
range (-767591973226673249,-759782651038439858] finished
[2014-06-17 22:01:38,932] Repair session f1bc42a0-f66a-11e3-8ad4-251897e18719 for
range (1226781783220621999,1238805897799045860] finished
[2014-06-17 22:01:38,947] Repair session f2bee590-f66a-11e3-8ad4-251897e18719 for
range (7669322402280617470,7674157004615966047] finished
[2014-06-17 22:01:38,947] Repair command 2 finished
```

Dla zastosowań, w których wymagany jest ciągły nadzór administracyjny nad klastrem jest oczywiście możliwe wywoływanie polecenia nodetool repir ręcznie. Na potrzeby tego dokumentu przyjęto, że naprawy odbywać się będą tak, by tylko jeden węzeł był jednocześnie obciążany. Do wywoływania polecenia nodetool repair użyto crona (dla uproszczenia pominięto kwestie związane z uruchamianiem zadania poprzez dedykowanego użytkownika):

Listing 18: konfiguracja okresowego naprawiania klastra

```
$ echo "#!/bin/bash" > /root/repair-cassandra.sh
$ echo "nodetool -host localhost -p 7199 repair --partitioner-range" \
> >> /root/repair-cassandra.sh

$ chmod u+x /root/repair-cassandra.sh

$ crontab -e

GNU nano 2.2.6 File: /tmp/crontab.M3Zyaw/crontab Modified

# Edit this file to introduce tasks to be run by cron.

#
# Each task to run has to be defined through a single line
# indicating with different fields when the task will be run
# and what command to run for the task
#
# To define the time you can provide concrete values for
# minute (m), hour (h), day of month (dom), month (mon),
# and day of week (dow) or use '*' in these fields (for 'any').#
# Notice that tasks will be started based on the cron's system
```

```
# daemon's notion of time and timezones.
# Output of the crontab jobs (including errors) is sent through
# email to the user the crontab file belongs to (unless redirected).
# For example, you can run a backup of all your user accounts
# at 5 a.m every week with:
# 0 5 * * 1 tar -zcf /var/backups/home.tgz /home/
# For more information see the manual pages of crontab(5) and cron(8)
# m h dom mon dow command
0 3 * * <node_id> /root/repair-cassandra.sh
^G Get Help ^O WriteOut ^R Read File ^Y Prev Page ^K Cut Text ^C Cur Pos
^X Exit ^J Justify ^W Where Is ^V Next Page ^U UnCut Text ^T To Spell
$ ^ X
$ crontab -u root -l
# Edit this file to introduce tasks to be run by cron.
# Each task to run has to be defined through a single line
# indicating with different fields when the task will be run
# and what command to run for the task
# To define the time you can provide concrete values for
# minute (m), hour (h), day of month (dom), month (mon),
# and day of week (dow) or use '*' in these fields (for 'any').#
# Notice that tasks will be started based on the cron's system
# daemon's notion of time and timezones.
# Output of the crontab jobs (including errors) is sent through
# email to the user the crontab file belongs to (unless redirected).
# For example, you can run a backup of all your user accounts
# at 5 a.m every week with:
# 0 5 * * 1 tar -zcf /var/backups/home.tgz /home/
# For more information see the manual pages of crontab(5) and cron(8)
# m h dom mon dow command
1 1 * * 1 /root/repair-cassandra.sh # repairing one node per day of week;
                                # should be enough for 3 nodes in cluster
```

UWAGA! Można dodatkowo zredukować obciążenie węzła podając przy naprawie parametr -partitioner-range. Spowoduje to naprawę jedynie tych zakresów kluczy dla których węzeł jest master repliką (pomijając zakresy ulokowane w węźle przez mechanizm replikacji — standardowe repliki).

UWAGA! Synchronizacja replik na żądanie spowoduje automatycznie usunięcie wszystkich *tombstonów* związanych z replikowaną rodziną kolumn, ponieważ po synchronizacji nie są one już potrzebne.

5.3.3 Konfiguracja uwierzytelniania

Włączenie uwierzytelniania klienta wymaga w pierwszej kolejności zmiany mechanizmu uwierzytelniania w pliku konfiguracyjnym /etc/cassandra/cassandra.yaml. Domyślnie Cassandra używa implementacji AllowAllAuthenticator, który pozwala każdemu na dostęp do klastra, jednocześnie blokując wykonywania jakichkolwiek operacji na zbiorze użytkowników:

Listing 19: wypisanie listy zdefiniowanych użytkowników przy wyłączonym uwierzytelnianiu

```
$ cqlsh
Connected to OAND1AND2CLUSTER at localhost:9160.
[cqlsh 4.1.1 | Cassandra 2.0.8 | CQL spec 3.1.1 | Thrift protocol 19.39.0]
Use HELP for help.
cqlsh> LIST USERS;
Bad Request: You have to be logged in and not anonymous to perform this request
cqlsh>
```

Zmieniając parametr authenticator na *PasswordAuthenticator* wyłącza się możliwość anonimowego logowania do klastra, zyskując w to miejsce możliwość zarządzania użytkownikami. Domyślny użytkownik administracyjny ma przypisany login cassandra i hasło cassandra. Podając te dane przy logowaniu zyskujemy możliwość zmiany domyślnego hasła i utworzenia standardowego użytkownika:

Listing 20: włączenie uwierzytelniania przy dostępie do klastra przez cqlsh

Listing 21: konfiguracja kont użytkowników

```
$ cqlsh -u cassandra -p cassandra
Connected to OAND1AND2CLUSTER at localhost:9160.
[cqlsh 4.1.1 | Cassandra 2.0.8 | CQL spec 3.1.1 | Thrift protocol 19.39.0]
Use HELP for help.
cqlsh> ALTER USER cassandra WITH PASSWORD 'balcerowiczmusiodejsc';
cqlsh> CREATE USER scott WITH PASSWORD 'tiger' NOSUPERUSER;
cqlsh> quit;
```

Listing 22: weryfikacja konfiguracji kont użytkowników

Oczywiście włączenie uwierzytelniania ma wpływ na wszystkie kanały komunikacji z klastrem, w tym na drivery *DataStax*.

6 Zarządzanie klastrem

6.1 Monitoring węzłów i klastra

Początkowo *Cassandra* przekazywała szereg statystyk, głównie dot. wydajności (np. opóźnienie odczytów i zapisów, liczba uruchomień procesów kompaktowania struktur danych, użycie pamięci podręcznej, itd.) do systemu monitorowania klastrów *Ganglia* [1] [7].

Obecnie *Cassandra* do tego celu wykorzystuje technologię *JMX*, która może być traktowana jako odpowiednik *SNMP* dla serwerów pisanych w *Javie*, dodatkowo wyposażony w mechanizm RPC.

Absolutna większość narzędzi do monitorowania klastrów potrafi komunikować się z agentami *JMX* (np. *Nagios*, *Munin*). Istnieją też konwertery/mosty pomiędzy technologiami, pozwalające odpytywać agenta *JMX* przez np. REST (*JMX-to-REST*, http://code.google.com/p/polarrose-jmx-rest-bridge/) czy *SNMP* (*jmx2snmp*, https://github.com/tcurdt/jmx2snmp).

Istnieje też narzędzie pozwalające dodać do Cassandry konsolę WWW wyświetlającą metryki udostępnianie przez agenta.

By dodać taką konsolę należy poprać narzędzie MX4J (http://mx4j.sourceforge.net/), wypakować zawartość pobranego archiwum, a następnie dodać archiwum mx4j-tools.jar do ścieżki systemowej Javy (classpath) definiowanej na potrzeby Cassandry. Standardowo by to zrobić, wystarczy skopiować plik mx4j-tools.jar do katalogu /usr/share/cassandra/lib/.

By zdefiniować adres i port na którym ma nasłuchiwać konsola WWW, należy przekazać dodatkowe parametry do maszyny wirtualnej. Stąd do pliku /etc/cassandra/cassandra-env.sh należy dopisać następujące linijki:

Listing 23: konfiguracja mx4j dla Cassandry

```
JVM_OPTS="$JVM_OPTS -Dmx4jaddress=0.0.0.0"
JVM_OPTS="$JVM_OPTS -Dmx4jport=8081"
```

By sprawdzić czy narzędzie zostało załadowane, należy zrestartować usługę cassandra i przeszukać plik logu pod kątem odpowiedniego wpisu. Oczywiście można też sprawdzić czy *Cassandra* nasłuchuje na odpowiednim porcie.

Listing 24: weryfikacja poprawności działania mx4j

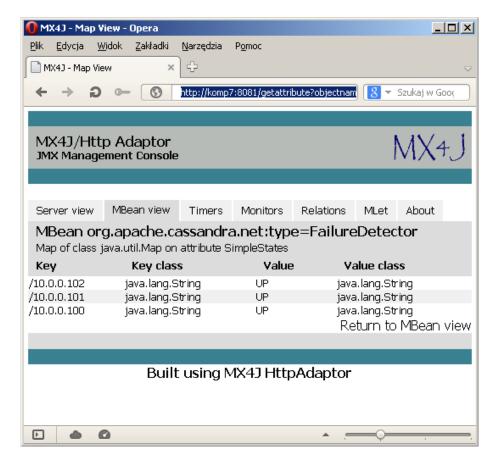
```
$ cat /var/log/cassandra/system.log | grep mx4j

[...]

INFO [main] 2014-06-18 00:47:06,506 Mx4jTool.java (line 63) mx4j successfuly loaded

$ netstat -ln4p | grep 8081
tcp 0 0 0.0.0.0:8081 0.0.0.0:* LISTEN 2651/java
```

Pod tak zdefiniowanym adresem można znaleźć konsolę dającą dostęp do metryk udostępnianych za pośrednictwem JMX:



Rysunek 2: konsola MX4J, podgląd stanu detektora awarii w węźle 10.0.0.100

Oczywiście narzędzie nodetool także pozwala wyświetlić parametry pracy węzła:

Listing 25: statystyki dla puli wątków z podziałem na zadania

\$ nodetool -host localhost tpstats						
Pool Name	Active	Pending	Completed	Blocked	Alltime	blocked
ReadStage	0	0	2	0		0
RequestResponseStage	0	0	2	0		0
MutationStage	0	0	122	0		0
ReadRepairStage	0	0	0	0		0
${\tt ReplicateOnWriteStage}$	0	0	0	0		0
GossipStage	0	0	4236	0		0
${\tt CacheCleanupExecutor}$	0	0	0	0		0
MigrationStage	0	0	0	0		0
MemoryMeter	0	0	13	0		0
FlushWriter	0	0	8	0		0
ValidationExecutor	0	0	0	0		0
${\tt InternalResponseStage}$	0	0	0	0		0
AntiEntropyStage	0	0	0	0		0
${ t MemtablePostFlusher}$	0	0	42	0		0
MiscStage	0	0	0	0		0
PendingRangeCalculator	. 0	0	5	0		0
CompactionExecutor	0	0	43	0		0
commitlog_archiver	0	0	0	0		0
HintedHandoff	0	0	2	0		0
Message type	Droppe	ed				
RANGE_SLICE		0				
READ_REPAIR		0				
PAGED_RANGE		0				
BINARY		0				
READ		0				
MUTATION		0				
_ TRACE		0				
REQUEST_RESPONSE		0				
COUNTER_MUTATION		0				

```
$ nodetool -host localhost cfstats
[...]
Keyspace: system_auth
       Read Count: 2
       Read Latency: 43.764 ms.
       Write Count: 3
       Write Latency: 49.754 ms.
       Pending Tasks: 0
[...]
              Table: users
              SSTable count: 1
              Space used (live), bytes: 4689
              Space used (total), bytes: 4689
              SSTable Compression Ratio: 0.7611940298507462
              Number of keys (estimate): 128
              Memtable cell count: 0
              Memtable data size, bytes: 0
              Memtable switch count: 1
              Local read count: 1
              Local read latency: 0.000 ms
              Local write count: 1
              Local write latency: 0.000 ms
              Pending tasks: 0
              Bloom filter false positives: 0
              Bloom filter false ratio: 0.00000
              Bloom filter space used, bytes: 16
              Compacted partition minimum bytes: 61
              Compacted partition maximum bytes: 72
              Compacted partition mean bytes: 72
              Average live cells per slice (last five minutes): 1.0
              Average tombstones per slice (last five minutes): 0.0
```

6.2 Przyłączanie i odłączanie węzłów

By dodać do klastra nowy węzeł w celu odciążenia pozostałych, należy wykonać procedurę analogiczną do opisanej w punkcie 5.1. Istnieje możliwość wyspecyfikowania w pliku konfiguracyjnym za ile tokenów (a nawet za jakie dokładnie) nowy węzeł będzie odpowiedzialny, ale nawet bez takiej informacji nowy węzeł będzie w stanie skutecznie odciążyć klaster, ponieważ dzięki gossippingowi ma wgląd w stan wszystkich innych węzłów.

Powodów by odłączyć węzeł może być kilka:

- klaster podlega aktualnie skalowaniu "w dół" i zbędne węzły są usuwane, choć cały czas działają prawidłowo
- węzeł działa, choć niestabilnie est spora szansa na to, że w najbliższym czasie ulegnie awarii, powinien więc być zastąpiony nowym
- węzeł już uległ awarii i nie odpowiada na zapytania, jednak inne węzły cały czas próbują się z nim kontaktować

W pierwszym przypadku węzeł można odłączyć przy pomocy procesu którego nazwę autorzy pozwolili sobie przetłumaczyć jako "złomowanie" (ang. decommissioning). W jego wyniku tokeny złomowanego węzła zostają usunięte z pierścienia, a dane, które się na nim znajdują są transferowane do nowych odpowiedzialnych za nie węzłów.

W praktyce złomowanie węzła sprowadza się do wykonania jednego polecenia za pośrednictwem narzędzia nodetool:

Listing 27: stan klastra z perspektywy węzła w nim pozostającego

```
$ nodetool status
Note: Ownership information does not include topology; for complete information,
specify a keyspace
Datacenter: DC1
==========
Status=Up/Down
|/ State=Normal/Leaving/Joining/Moving
-- Address Load Tokens Owns Host ID Rack
UN 10.0.0.101 115.51 KB 256 32.8% d6537c65-2a7a-4359-a451-fdb4c6685b0c NODE1AND2
UN 10.0.0.100 154.59 KB 256 35.0% ac12364d-1ed1-4d8b-b667-0817f75dc065 NODE0
UN 10.0.0.102 115.33 KB 256 32.2% ecdf71d2-1a4b-4727-bad6-8e293a0acbe3 NODE1AND2
```

Listing 28: odłączenie węzła NODE2/10.0.0.102

\$ nodetool decommission

Listing 29: stan klastra z perspektywy węzła w nim pozostającego po odłączeniu węzła NODE2

```
$ nodetool status
Note: Ownership information does not include topology; for complete information,
specify a keyspace
Datacenter: DC1
===========
Status=Up/Down
|/ State=Normal/Leaving/Joining/Moving
-- Address Load Tokens Owns Host ID Rack
UN 10.0.0.101 125.02 KB 256 50.7% d6537c65-2a7a-4359-a451-fdb4c6685b0c NODE1AND2
UN 10.0.0.100 154.59 KB 256 49.3% ac12364d-1ed1-4d8b-b667-0817f75dc065 NODE0
```

UWAGA! Żadne dane nie są usuwane ze złomowanego węzła, więc jeżeli ma on być ponownie wykorzystany w innym miejscu pierścienia (z innym tokenem), należy wpierw opróżnić jego katalog danych ręcznie.

W drugim przypadku może być potrzebna naprawa klastra po tymczasowej (ang. transient) awarii węzła. Standardowe mechanizmy zapewniania ostatecznej spójności są w stanie rozwiązać problemy pojawiające się w takiej sytuacji, z jednym wyjątkiem. Gdy awaria trwa dłużej niż wynosi okres życia tombstonów, uszkodzony węzeł mógł nie zarejestrować pewnych operacji usunięcia wierszy.

Wtedy zaleca się wyczyszczenie węzła (usunięcie zawartości jego katalogu danych), usunięcie związanych z nim tokenów z pierścienia i ponowne dodanie do klastra:

```
$ nodetool ring
Datacenter: DC1
Address Rack Status State Load Owns Token
                                                4960255647790084904
10.0.0.100 NODEO Up Normal 35.91 KB 81.40% -8739202312123959326
10.0.0.101 NODE1AND2 Down Normal 35.88 KB 44.33% -5308254802912860692
10.0.0.102 NODE1AND2 Up Normal 35.92 KB 74.26% 4960255647790084904
$ nodetool status
Datacenter: DC1
_____
Status=Up/Down
|/ State=Normal/Leaving/Joining/Moving
-- Address Load Tokens Owns (effective) Host ID Rack
DN 10.0.0.101 35.88 KB 1 44.3% f329244e-c4ac-4fb0-8343-4476d97a311f NODE1AND2
UN 10.0.0.100 35.91 KB 1 81.4% ae935af3-d6b9-433a-a359-a6ef623340fe NODE0
UN 10.0.0.102 35.92 KB 1 74.3% b5c8225f-aff8-4e7d-9d82-221dc113adad NODE1AND2
$ nodetool removenode f329244e-c4ac-4fb0-8343-4476d97a311f
$ nodetool status
Datacenter: DC1
______
Status=Up/Down
|/ State=Normal/Leaving/Joining/Moving
-- Address Load Tokens Owns (effective) Host ID Rack
UN 10.0.0.100 35.91 KB 1 100.0% ae935af3-d6b9-433a-a359-a6ef623340fe NODEO
UN 10.0.0.102 35.92 KB 1 100.0% b5c8225f-aff8-4e7d-9d82-221dc113adad NODE1AND2
$ nodetool ring
Datacenter: DC1
Address Rack Status State Load Owns Token
                                               4960255647790084904
10.0.0.100 NODEO Up Normal 35.91 KB 100.00% -8739202312123959326
10.0.0.102 NODE1AND2 Up Normal 35.92 KB 100.00% 4960255647790084904
```

UWAGA! Różnica pomiędzy operacją decommission a removenode jest taka, że druga z nich zakłada że usuwany węzeł nie działa. W związku z tym nowe węzły odpowiedzialne za zwalniany zakres tokenów będą pobierały dane z pozostałych w systemie replik, podczas gdy w trakcie złomowania źródłem danych będzie złomowany węzeł.

Wreszcie w przypadku całkowitej awarii węzła znaczącą rolę będzie miało opóźnienie odczytów i zapisów związane z "problemami technicznymi" i/lub niespójność danych.

Gdy każdy z węzłów ma przydzielony tylko jeden token (przydzielany ręcznie), można ten problem rozwiązać następująco:

- 1) należy zastępczy węzeł odpowiednio przygotować poprzez nadanie mu adresu IP innego niż poprzednikowi i tokenu mniejszego o 1 od tokenu poprzednika
- podczas przyłączenia do klastra węzeł nie będzie odpowiadał na żądania odczytu aż do momentu zakończenia tego procesu

- 3) po przyłączeniu zastępcy martwy węzeł będzie odpowiadał tylko za jeden token należy go usunąć z pierścienia poleceniem nodetool removetoken
- 4) na każdym z pozostałych węzłów należy wykonać polecenie nodetool cleanup, by uaktualnienia tam zapamiętane w efekcie działania mechanizmu *HintedHandoff* niepotrzebnie nie zajmowały miejsca nigdy nie dotrą one do celu ponieważ węzeł, do którego były adresowane został trwale usunięty z klastra

W przypadku standardowej konfiguracji (wiele tokenów dla pojedynczego węzła, dodatkowo przydzielanych automatycznie), procedura naprawy polega na podłączeniu zastępcy z takim samym adresem IP i uruchomieniu na nim polecenia nodetool repair. Jest to o tyle kłopotliwe, że dla odczytów z żądanym niskim poziomem spójności (np. ONE) węzeł przez okres naprawy (który może być bardzo długi) będzie zwracał klientom informację o braku danych.

Literatura

- A. Lakchman, P. Malik,
 Cassandra A Decentralized Structured Storage System,
 ACM SIGOPS Operating Systems Review,
 Volume 44 Issue 2, April 2010
- [2] Jan Baranowski, Michał Kaik, Maciej Urbański, Cassandra, Highly available, scalable storage system, Politechnika Poznańska 2014
- [3] E. Hewitt, Cassandra, The Defintive Guide, O'Reilly 2010
- [4] DataStax, http://www.datastax.com/, dostep 17 czerwca 2014 r.
- [5] DebianPackaging, Cassandra Wiki, https://wiki.apache.org/cassandra/DebianPackaging. dostep 16 czerwca 2014 r.
- [6] Distributed Deletes, Cassandra Wiki, http://wiki.apache.org/cassandra/Distributed Deletes dostęp 17 czerwca 2014 r.
- [7] Ganglia Monitoring System, http://ganglia.sourceforge.net/dostęp 18 czerwca 2014 r.
- [8] GettingStarted, Cassandra Wiki, http://wiki.apache.org/cassandra/GettingStarted, dostęp 16 czerwca 2014 r.
- [9] Daniel Stavrovski, Installing Oracle JAVA 7 on Debian Wheezy, http://d.stavrovski.net/blog/post/installing-oracle-java-7-on-debian-wheezy, dostęp 16 czerwca 2014 r.
- [10] Java/Sun, Debian Wiki, https://wiki.debian.org/Java/Sun, dostęp 16 czerwca 2014 r.
- [11] MySQL Connectors, http://www.mysql.com/products/connector/, dostęp 16 czerwca 2014 r.
- [12] NoSQL Apache Cassandra Documentation, http://planetcassandra.org/documentation/, dostep 16 czerwca 2014 r.
- [13] NTP, Debian Wiki, https://wiki.debian.org/NTP, dostęp 16 czerwca 2014 r.
- [14] Operations, Cassandra Wiki, http://wiki.apache.org/cassandra/Operations, dostęp 16 czerwca 2014 r.

[15] Why DataStax?, http://www.datastax.com/why-datastax dostęp 16 czerwca 2014 r.

 $\underline{ \text{Tablica 1: podstawowe parametry konfiguracyjne } \textit{Cassandry (w/etc/cassandra/cassandra.yaml)}.}$

Parametr L		Komentarz
cluster_name	10	nazwa klastra, którego ten węzeł jest członkiem
authenticator	64	Klasa implementująca mechanizm uwierzytelniania. Do wyboru: AllowAllAuthenticator i PasswordAuthenticator. W drugim przypadku nazwy użytkowników i hasła przechowywane są wewnątrz bazy danych w przestrzeni kluczy system_auth.
auhorizer	73	Klasa implementująca mechanizm sprawdzania uprawnień przy dostępie do danych (autoryzację). Do wyboru AllowAllAuthorizer i CassandraAuthorizer. W drugim przypadku uprawnienia przechowywane są wewnątrz bazy danych w przestrzeni kluczy system_auth.
seed_provider/parameters/seeds	192	Węzeł Cassandry nie odkrywa innych węzłów automatycznie, stąd dla algorytmu plotkowania wymagana jest lista początkowych "punktów kontaktowych". Oczywiście punkty powinny być tak dobrane by nie dopuścić do partycjonowania klastra.
listen_address	297	Adres IP kanału komunikacyjnego pomiędzy węzłami. Agent algorytmu plotkującego będzie nasłuchiwał na tym adresie. Jeżeli wartość nie zostanie tutaj podana, <i>Cassandra</i> wybierze adres IP localhosta.
start_native_transport	310	Czy uruchomić binarny protokół transportowy wykorzystywany przez drivery DataStax.
native_transport_port	312	Port dla binarnego protokołu transportowego. Jest on podawany w kodzie klienta gdy ten łą- czy się z określonym węzłem klastra.
start_rpc	324	Czy uruchomić serwer <i>Thrift RPC</i> . Wyłączenie serwera RPC uniemożliwi dostęp do węzła przez np. cqlsh.
rpc_address	335	Adres IP na którym ma nasłuchiwać serwer $Thi-fta$.